GROUP ASSIGNMENT

澳門城市大學
Universidade da Cidade de Macau
City University of Macau

Title: [澳门气温专题——多模型气温预测]

Group member:

[罗竣一;D23090105453]

[姚志霖;D23090110182]

[王苏赜; D23090105247]

Declaration for Contributions

罗竣一： 负责研究设计的整体架构； 使用 **R 语言以及 python** 编写并实现多元线性回归 (MLR)、广义相加模型 (GAM) 以及长短期记忆网络 (LSTM) 模型代码； 执行特征工程、PCA 降维及模型超参数调优 。

姚志霖： 负责从澳门地球物理气象局爬取 2021-2025 年原始气象数据； 执行数据清洗与预处理; 使用 **Tableau** 制作附录中的所有可视化图表

王苏赜： 负责背景研究与背景意义撰写（旅游业影响分析）； 执行单因素方差分析 (ANOVA) 的逻辑校验； 负责报告的中英文排版、参考文献整理及最终合规性检查 。

Date: 2026/04/24

Abstract

澳门作为世界级旅游休闲中心，其日平均气温的剧烈波动不仅直接影响游客的户外出行体验与健康安全，更对酒店业的能源调度与旅游景区的客流管理构成了严峻挑战。针对澳门气温难以精准预测的业务痛点，本研究基于澳门地球物理气象局 2021 至 2025 年的气象数据，开展了严谨的统计学特征工程与多模型气温预测架构对比研究。意图构建轻量化且适用于澳门地区的精准气温预测模型，为游客出行与澳门旅游业发展提供助力。研究首先通过数据离散化（Binning）对分布离散的湿度、风速和日照等变量进行降维分级；随后通过散点图与 Correlation matrix 识别连续变量的线性/非线性分布及多重共线性风险，并利用单因素方差分析（ANOVA）严格验证了分类变量的全局显著性。在预测实验中，本研究设计了“带 PCA 降维”与“不带 PCA 降维”的多元线性回归（MLR）与广义相加模型（GAM）的 对比试验，并延伸了长短期记忆网络（LSTM）作为深度学习参照组。实验结果表明：在处理具有独立非线性物理规律的气象特征时，强行施加 PCA 纯线性投影会导致预测信息丢失；而不经 PCA 线性污染、保留原生关联变量并引入年积日平滑项的 GAM 模型，成功克服了共线性内耗，在测试集（2025 年）上取得了超越复杂 LSTM 网络的最优泛化预测性能，论文架构图见图 0

Keywords： 旅游业；澳门气温预测；广义相加模型 (GAM)；长短期记忆网络 (LSTM)；多元线性回归 (MLR)；主成分分析 (PCA)；特征离散化；方差分析 (ANOVA)

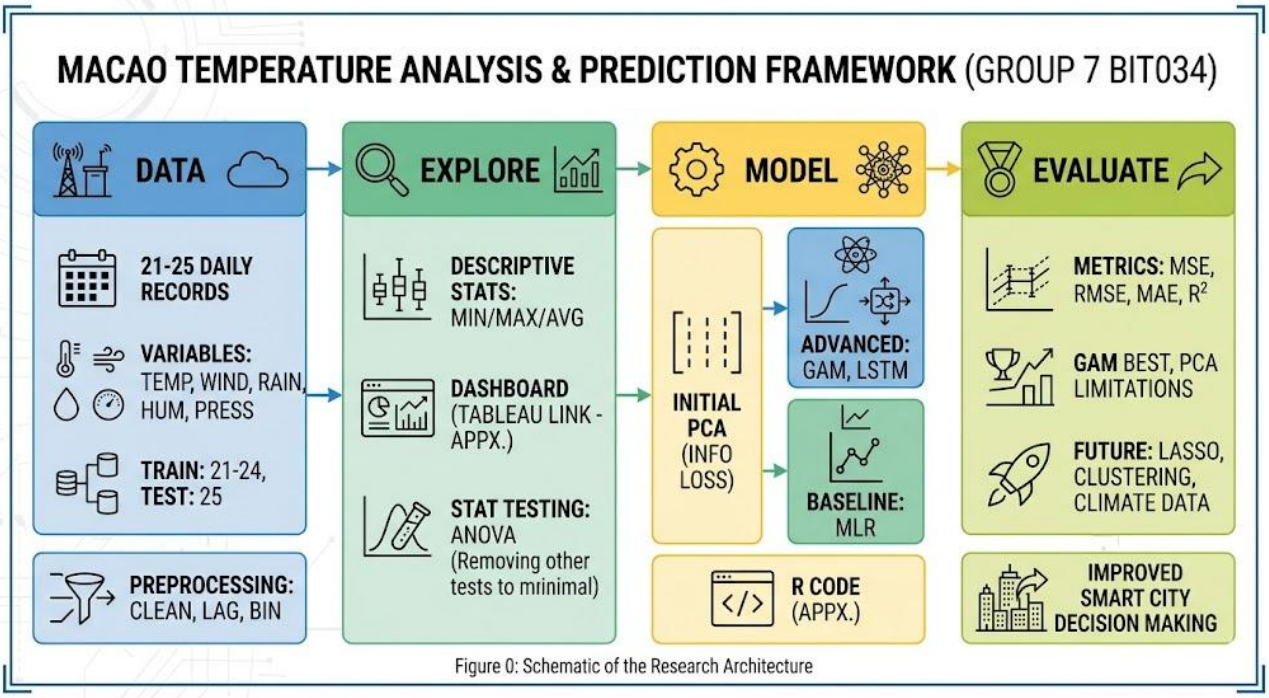

图.0 论文架构图

Introduction

气候条件是影响旅游目的地吸引力的核心要素之一。澳门夏季炎热多雨、冬季湿冷，突变的气温常导致户外旅游活动（如大三巴牌坊观光）受阻，并引发酒店空调能耗的剧烈波动。精准的气温预测不仅能为游客提供出行指南，更能帮助旅游管理部门进行预警。本研究涉及以下核心方法：

1. **MLR(多元线性回归)**
   (1) MLR 作为经典的统计学基准模型，适用于探究响应变量（日均温）与多个预测变量（如特征降维后的主成分、分类气象变量）之间的纯线性关系。本研究将其作为对照实验的核心底座，旨在通过纯线性拟合的误差表现，反向验证并凸显气象数据中潜在的复杂非线性规律。
   (2) 底层数学架构：MLR 在底层严格遵循：$Y = \beta_0 + \beta_1 * X_1 + \cdots + \beta_k * X_k + \epsilon$的线性方程架构。模型将分类变量转化为改变截距 β_0的平移开关，将连续变量与斜率系数 β_k 结合，并通过最小二乘法（Least Squares）估算这些固定参数，从而确保所有样本预测残差的平方和达到最小。
2. **GAM(广义相加模型)：**在 MLR 基准模型的基础上，为了突破纯线性的架构死锁，本研究附加引入了 GAM。由于本研究涉及的任务包含连续量数据（如年积日等），且这些数据具有明显的时间依赖性，加之散点图分析证实部分数据与平均气温呈显著非线性关系，GAM 适合作为任务的延伸。
   (1) **平滑函数的应用：**GAMs 允许使用平滑函数 $f_j(x_{ij})$ 来建模响应变量 μ_i 对预测变量 x_{ij} 的依赖关系。例如，可以将年积日（一年中的第几天）作为平滑项，以捕捉气温数据中的季节性趋势或周期，而无需事先设定固定的周期函数。
   (2) **模型可解释性强：**与机器学习黑盒方法相比，GAM 继承了统计学方法的透明优势，其解释性明显优于复杂网络，可以帮助我们快速定位气象预测中的问题与物理优势所在。
3. **One-Way ANOVA(单因素方差分析)：**单因素方差分析适用于检验单一分类变量对连续型响应变量的影响。本研究将其作为特征预处理的核心检验接口，用于筛选对日均温具有显著整体影响的分类气象特征（如离散化区间分箱后的湿度、风速等级以及风向、月份等），为下游回归模型确立严格的特征准入边界
4. **PCA(主成分分析)：**PCA 是一种用于消除变量间多重共线性的数据降维技术。本研究的连续型滞后气象变量（如前两天的气压、露点、均温）两两之间呈现极强的线性相关，因此引入 PCA 作为特征处理的控制变量对照组，旨在通过线性投影提取相互独立的主成分，以期消除模型的计算内耗
5. **LSTM(长短期记忆网络)：**LSTM 是一种特殊的循环神经网络（RNN），由 Hochreiter 和 Schmidhuber 于 1997 年提出，专门用于解决传统 RNN 在处理长序列时面临的梯度消失或梯度爆炸问题 。
   (1) **核心机制 (CEC)：**LSTM 的核心创新在于引入了 Constant Error Carrousel (CEC），它通过强制误差流在特殊的单元内保持恒定，从而解决了长期依赖学习中的误差衰减问题，使得 LSTM 能够跨越超过 1000 个离散时间步长来桥接时间滞后[1]，理论上非常适合捕捉澳门气温这种既受短期天气突变影响，又受长期季节性因素制约的时间序列数据
   (2) **门控机制 (Gating)：**LSTM 引入了乘法门单元（输入门和输出门）。输入门控制何时将新的气象信息写入记忆细胞，输出门控制何时读取记忆细胞的状态 。这种机制赋予了模型对气温数据中“噪声”的鲁棒性，使其能够在含有噪声或不可压缩的输入序列中有效学习

Dataset & Preprocessing

本研究数据爬取自澳门地球物理气象局。时间跨度为 2021-01-01 至 2025-12-31，共计 1836 条数据，涵盖气压、气温、露点、湿度、风速等指标。为了满足严谨的统计学建模规范，预处理流程如下

- **处理流程：**
  - 进行了经典的缺失值处理，但对异常值并不进行删除，因为经过调查此处异常值并非数据本身错误，而是澳门气温突变的特性，需要纳入分析范围之内。
  - 构建表征时间周期的“年积日（Yday）”变量，以及基于前两天数据的滞后变量（如前 1 天均温 Avg_Temp_1、前 2 天气压 Pressure_2 等），详情见表 1

日期	**平均气温**	**一天前均温**	**两天前均温**	其它滞后变量	**年积日**
2021-01-03	**A**	**X**	**Y-**	……	**1**
2021-01-04	**B**	**A**	**Z**	……	**2**
2021-01-05	**C**	**B**	**A**	……	**3**
2021-01-06	**D**	**C**	**B**	……	**4**

表.1

- **数据离散化：**
  - 对于湿度、风速与日照时长这些分布偏向离散的数据，将其数值属性替换为区间标签：湿度转化为 Low/Medium/High/Super high 4 个等级；风速转化为 Low/High 2 个等级；日照时间拼接前缀转为文本因子。这三个变量与“月份”、“风向”一同作为分类变量（Factors）进入下游分析。所有分类变量可见表 1-1

日期	年份	月份	前一天湿度等级	前一天风速等级	前一天日照时长	当日风向
2021-01-03	**A**	1	**D**	**C**	……	**1**
2021-01-04	**A**	1	**A**	**D**	……	**2**
2021-01-05	**A**	1	**B**	**A**	……	**3**
2021-01-06	**A**	1	**C**	**B**	……	**4**

表.1-1

- **数据集划分：**
  - 2021/01/01 至 2024/12/31 的数据作为训练集进行拟合，2025 年全年数据作为未知测试集进行严格的泛化性能评估

Methodologies

1. 初步筛查可用变量：

a) 通过连续变量散点图与分类变量箱线图初步观察可以发现(可见附录图 1.1;1.2)，除了年积日与均温存在明显的非线性关系外，其余滞后变量都可初步假设与均温线性相关。并且通过箱线图发现除了年份以外（图 2），其余分类变量均可初步认为与均温相关，故准许进入下游 ANOVA 分析；

b) 将 6 个通过初步筛查的的连续变量用于拟合 MLR 模型，利用 R 语言输出摘要表，我们将摘要表重点信息归纳如下（见表 2）。根据多元线性回归的系数分析表显示，所有选取的滞后变量（前一天的均温、气压、露点温度等）的 P 值均小于 0.05。特别是前一天的平均气温（Avg_Temp_1）表现出极高的显著性，这验证了气温数据存在显著的时间滞后相关性，为后续构建预测模型提供了坚实的线性回归基础。

c) 接着我们在 6 个初步筛查的连续变量的基础上加上年积日，用于拟合 GAM 模型，摘要表重点信息归纳如下（见表 3）。通过表 3 可以看出年积日和前一日露点温度,前一天的平均气温，前两天的平均海平面气压 edf 值均远大于 2，这在数学上证明了澳门气温受季节和湿度（露点）和气压影响呈现显著的非线性特征，传统的线性模型（MLR）会遗漏这些重要信息，同时我们会将这四个连续变量作为平滑项引入 GAM

2. Correlation Analysis（连续变量共线性分析）：

a) 提取滞后连续变量计算相关性矩阵，结果显示除年积日外，其余滞后连续变量两两之间均出现显著的线性相关，面临严重的多重共线性风险。具体相关性数值可见图 3（相关性热力图见附录图 4）

3. ANOVA（分类变量方差分析）：

a) 对 5 个分类变量（月份、风向、前 1 天湿度等级、前 1 天风速等级、前 1 天日照等级）逐一进行单因素方差分析。结果证实它们与当日均温都有极其显著的关系（P 值极小），获准进入下游实验。具体数值见表 4

	F 值	P 值
月份	**628.0664**	**<2e-16**
当日风向	**49.3028**	**<2e-16**
前一日湿度等级	**117.5056**	**<2e-16**
前一日风速等级	**164.6907**	**<2e-16**
前一日日照时长	**28.2815**	**<2e-16**

表.4

4. PCA（主成分分析）：

a) 针对存在极强共线性的 6 个连续滞后变量（前两天的气压、露点、均温）执行 PCA 纯线性特征降维，以此构建实验组。通过多次检测发现，不可剔除任一 PCA 值，否则精度下降。

5. 实验设计：

a) **对照组：**本研究以输入 6 个原始滞后变量(前一日均温，前两日均温，前 1 日气压，前 2 日气压，前一日露点温度，前 2 日露点温度)为线性项，除年份以外的 5 个指标为分类变量的 MLR 为对照组
b) **实验组 1：**在对照组的基础上，把线性项改为 6 个 PCA 主成分，其余不变。
c) **实验组 2：**在对照组基础上，引入年积日、前一日均温，前一日露点温度、前 2 日气压作为平滑项，线性连续变量为剩下的三个连续变量，模型替换为 GAM;
d) **实验组 3：**在实验组 2 基础上并将线性项换为 3 个 PCA 主成分。
e) **实验组 4：**结合气温数据本身的时序特性，我们引入 LSTM 为延伸实验，意图观察复杂机器学习模型在天气预测任务中效果如何，为达到最优效果，我们对 LSTM 做了如下调整:
   i. 在 LSTM 主体部分我们采用双向 LSTM 层、同时加入 Dropout 机制，丢弃率设置为 0.2 防止模型过拟合、全连接层设置为 3 层逐步降维;
   ii. LSTM 主体之外我们还添加了早停机制，允许模型验证损失(val_loss)连续 20 次没有提升后才停止训练，并且设置 delta:损失提升的最小幅度。

	Estimate	T-value	Pr(>|t|)
前 1 日均温	**0.76626**	**14.642**	**< 2e-16**
前 2 日均温	**-0.07409**	**-2.096**	**0.036292**
前 1 日气压	**-0.07965**	**-3.396**	**0.000703**
前 2 日气压	**0.11633**	**4.938**	**8.85e-07**
前 1 日露点温度	**0.16839**	**3.996**	**6.77e-05**
前 2 日露点温度	**-0.12130**	**-4.720**	**2.59e-06**
R-sq(adj)	**0.9345**		
整体 P-value	**<2.2e-16**		

表.2

	edf	P-value
前 1 日均温	4.681	**< 2e-16**
前 2 日均温	1.770	0.00166
前 1 日气压	2.885	**9.04e-07**
前 2 日气压	5.103	**< 2e-16**
前 1 日露点温度	7.409	**9.00e-07**
前 2 日露点温度	2.637	**3.91e-07**
年积日	5.158	**< 2e-16**
R-sq(adj.)	0.939	
Devince explained	94%	

表.3

Results

1. 平均气温预测(评估指标见表 5)

a) 引入 PCA 降维的模型普遍预测效果弱于不引入 PCA 的模型，我们猜测原因在于纯线性投影破坏了原生变量的独立非线性信息；
b) 不论是否引入 PCA，GAM 预测指标均全面优于 MLR
c) 引入 PCA 的 GAM 虽然平均绝对误差高于普通 GAM,但整体来看，期预测稳定性最优
d) 通过评估指标表可看出 LSTM 出现过拟合风险（RMSE）上升。且在多方法综合比较中，保留原生变量的 GAM 模型在 MAE 与 RMSE 等关键指标上均优于复杂的机器学习 LSTM 模型
e) 5 个模型的最终预测折线图可见附录图 5；图 6（橙色线条为预测结果，黑色为真实值）

	MLR	PCA_MLR	GAM	PCA_GAM	LSTM
MAE	0.9862℃	0.9862℃	0.9676℃	0.9733℃	1.08℃
RMSE	1.3638℃	1.3638℃	1.3283℃	1.3321℃	1.45℃
RMSE/MAE	1.3829℃	1.3829℃	1.3728℃	1.3686℃	1.56℃

表.5

Conclusion

在预测情境下，强行施加 PCA 降维会引发预测性能下降；不经 PCA 线性污染、保留原生分类及连续变量，并针对年积日引入平滑项的广义相加模型（GAM），是本研究条件下计算效率最高、稳定性最强、预测精度最优的算法架构

Discussion, Biases & Future Improvements

- 尽管 GAM 模型表现优异，但本研究仅采用了过去四年的数据，存在一定的时间偏见（Time Bias），这导致模型可能无法捕捉如厄尔尼诺等更为宏观的长期气候周期影响。并且本研究并未侧重挖掘气温数据的时序特性以及 PCA 降维与 GAM 的融合效果不好，如果未来重做该研究，改进方案包括：
  - 引入 10 年以上维度长周期数据以消除短期波动；
  - 试在建模前调用聚类分析（Cluster analysis）对气候状态先行分类，再针对性拟合预测模型；
  - 添加回归模型岭回归 orLasso,尝试在不破换非线性物理因素的条件下进行降维；
  - 添加其它时序预测模型与 LSTM 对比实验；

References

[1] Hochreiter S, Schmidhuber J. Long Short-Term Memory[J]. Neural Computation, 1997, 9(8):1735-1780.

Appendix

（本文除共线性分析，所有图片均于 Tableau 绘制，相关文件已上传畅课，因本组资金短缺，Tableau Free 无法上传至 public,故只能麻烦前往压缩包查看 twb 文件核实）

（本研究所有代码可前往 github 链接查看，亦可在畅课查看；）

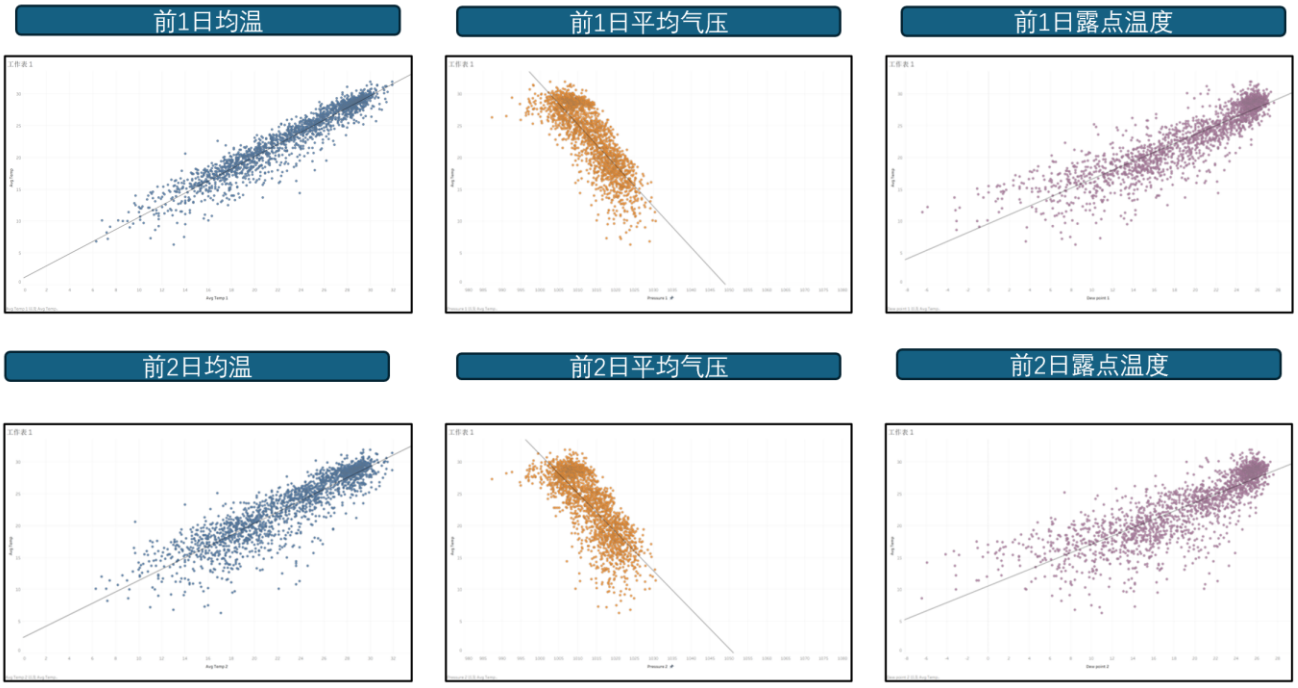

图.1.1 线性连续变量

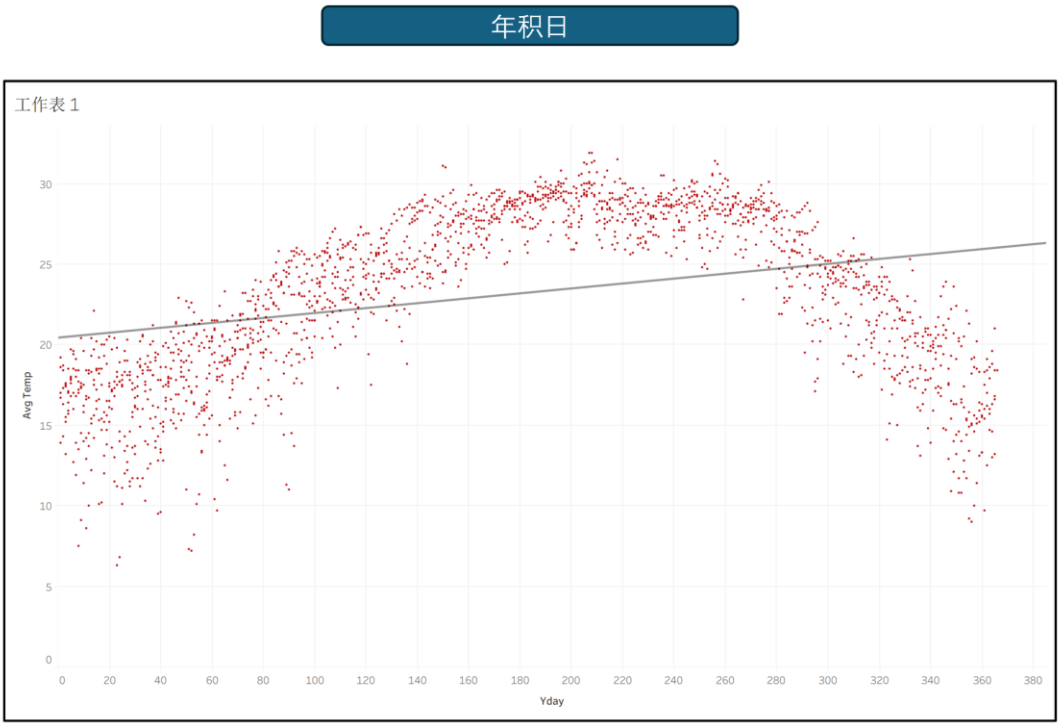

图 1.2 非线性连续变量

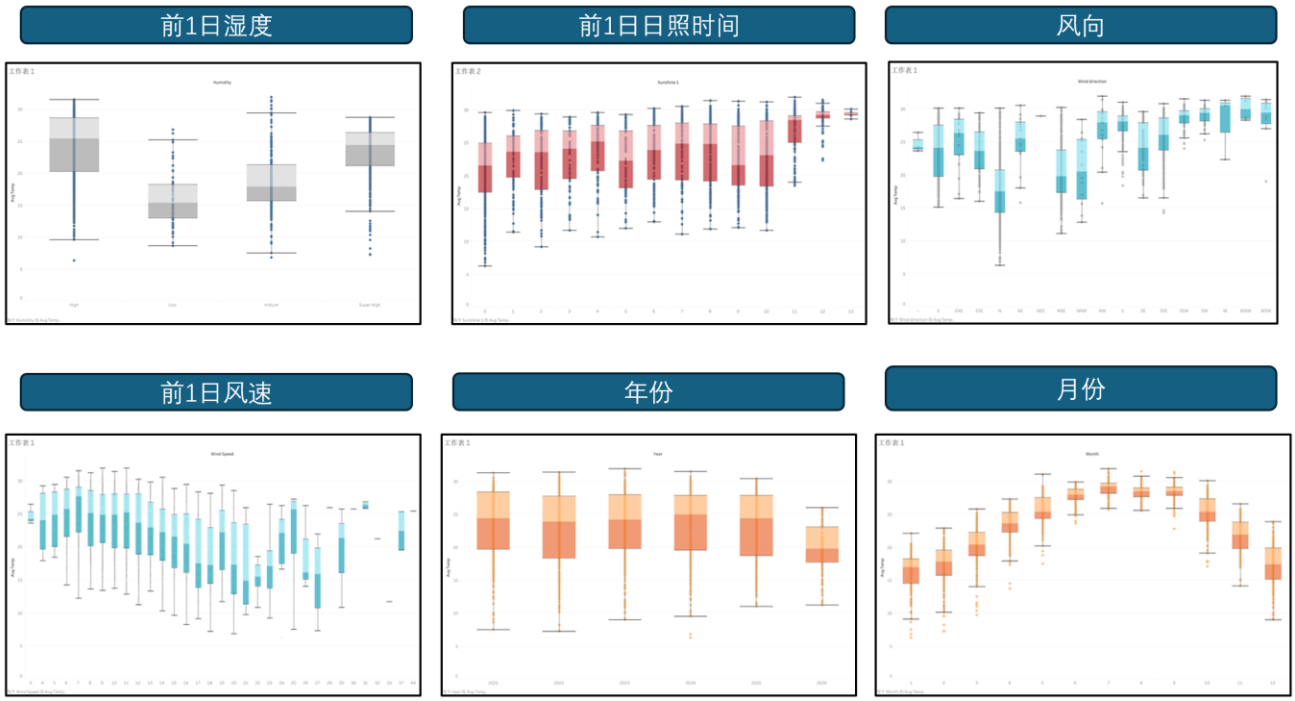

图.2 分类变量箱线图

```
Pressure_1      与 Avg_Temp_1      :  -0.8460
Pressure_1      与 Dew_point_1     :  -0.8564
Pressure_1      与 Pressure_2      :   0.9533
Pressure_1      与 Avg_Temp_2      :  -0.8353
Pressure_1      与 Dew_point_2     :  -0.8255
Avg_Temp_1      与 Dew_point_1     :   0.9259
Avg_Temp_1      与 Pressure_2      :  -0.8152
Avg_Temp_1      与 Avg_Temp_2      :   0.9559
Avg_Temp_1      与 Dew_point_2     :   0.8888
Dew_point_1     与 Pressure_2      :  -0.8362
Dew_point_1     与 Avg_Temp_2      :   0.8985
Dew_point_1     与 Dew_point_2     :   0.9454
Pressure_2      与 Avg_Temp_2      :  -0.8464
Pressure_2      与 Dew_point_2     :  -0.8564
Avg_Temp_2      与 Dew_point_2     :   0.9259
```

图.3 多重共线性数值分析

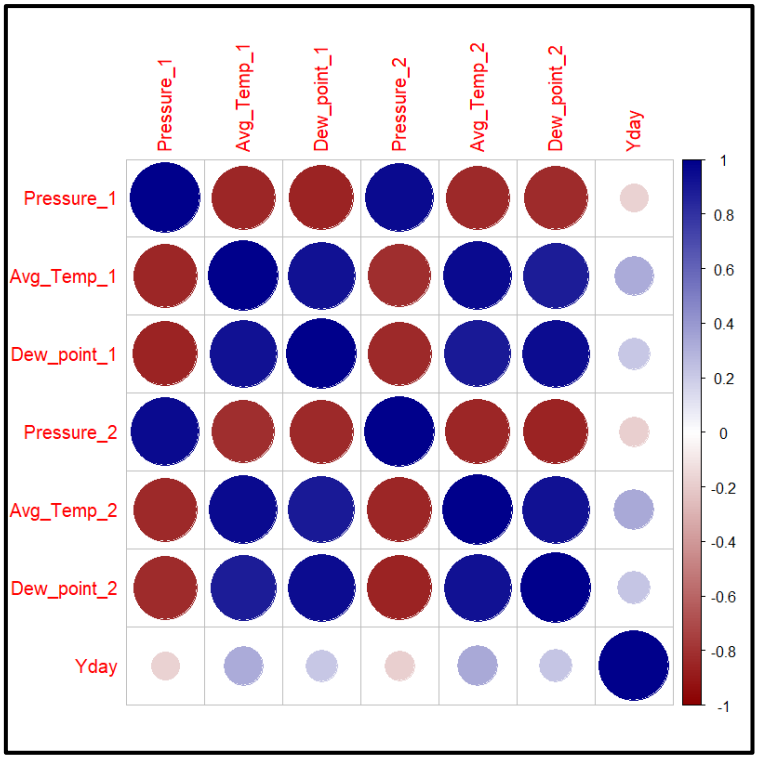

图.4 多重共线性热力图

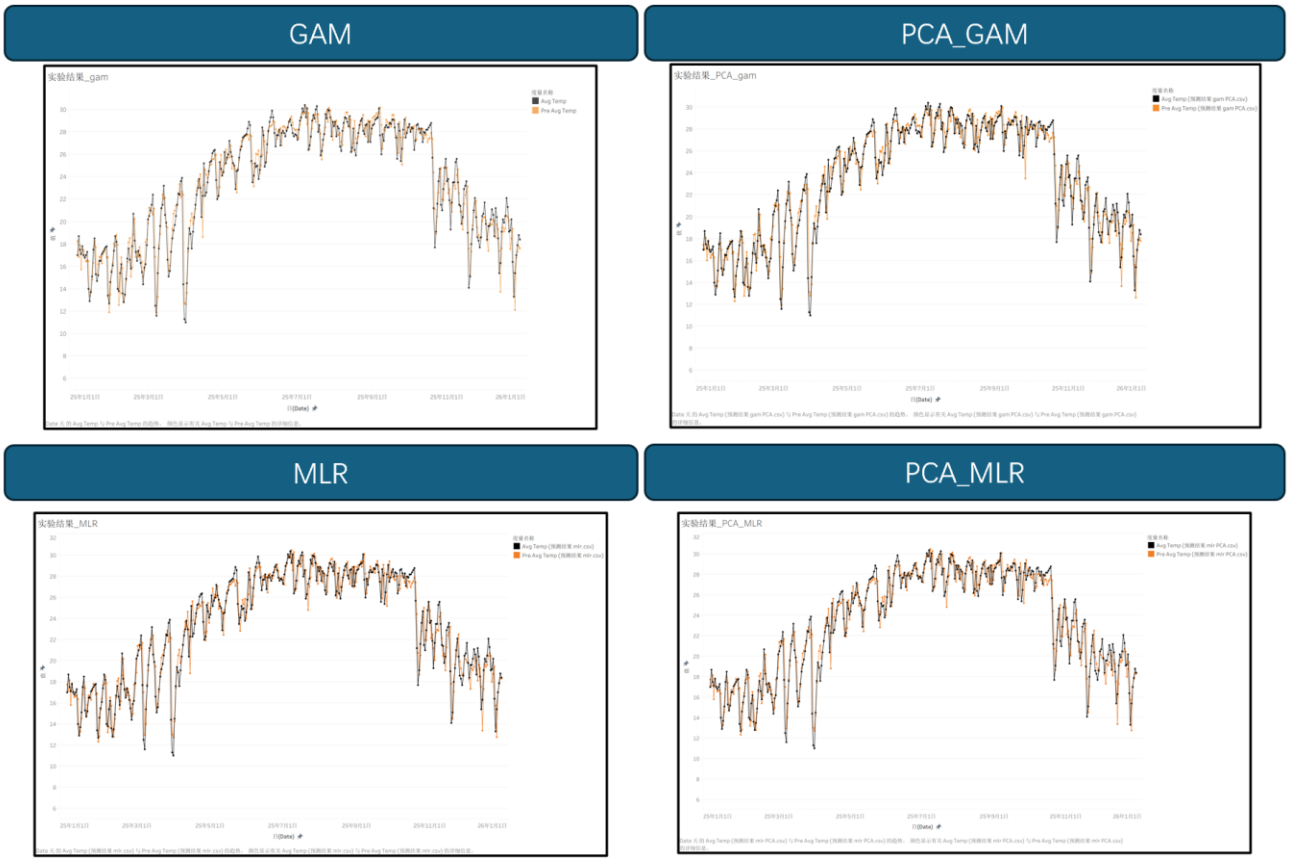

图.5 统计模型预测结果

LSTM

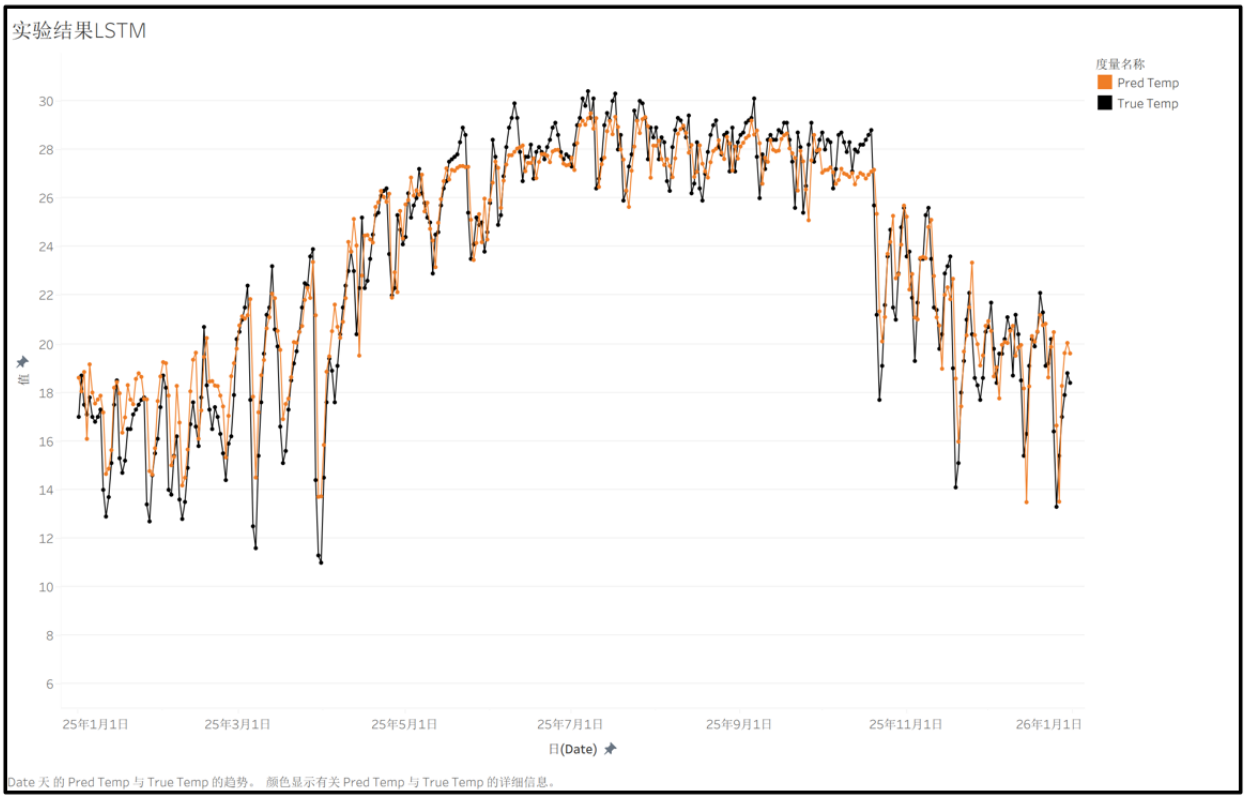

图.6 LSTM 结果图